

Lesson 3 – Questions

[**Basic Questions 25**]:

1. LM va LLM o'rtasida qanday farq bor?

↳ LM: text ni manosiga qarab keyingi suzni predict qiladi

LLM: katta dataset va kup parameterlarga ega bulgan LM hisoblanadi

2. LLM va SLM (Small Language Model) o'rtasida qanday farq bor?

↳ LLM: katta dataset va kup parameterlarga ega bulgan LM hisoblanadi

SLM: parameterlari kamroq buladi, kichik modellarda attention optimization muhimroq hisoblanadi

3. Bitter Lesson (Rich Sutton, 2019) nima?

↳ Faqat GPU kup bulishi yetarli emas, yaxshi algorithm kerak buladi. Eng yaxshi natija chiqishu uchun GPU va samaradorlik kerak buladi

4. Claude, ChatGPT va Gemini — bularni qanday model deb aytasiz?

↳ Frontier Models hisoblanadi. Yani hozirgi kundagi eng kuchli modellar dan biri

5. Claude, ChatGPT va Gemini oilalariga kiruvchi asosiy modellarni sanab bering.

↳ GPT-4, Claude 4, Gemini 2.5 Flash etc.

6. BPE (Byte Pair Encoding) nima?

↳ Eng yaxshi tokenization usuli. Suzlarni manosiga qarab kichik block larga ajratadi.

7. Tokenization nima va u nima uchun kerak?

↳ textning raqamga uzgartirish. Va suzlarni model osonroq tushunishi uchun kerak.

8. Trainingni boshlashdan oldin nimalarni hisobga olishimiz kerak?

↳ Compute (FLOPs) - parameter, token va batch size

Data - information sifati va filtering

VRAM (memory) - precision va parallelism

Hardware - GPU/TPU va node soni

Insoniy kuch - qanday tajriba uzkazilishi

9. Model parametrlari soni qanday hisoblanadi?

↳ $N = 12 * L * d^2$

N - parameterlar soni

L - layerlar soni

d - model dimension (d_model)

10. Model uchun kerakli xotira (memory) qanday hisoblanadi?

↳ $\text{Memory} = 16 * B * N$

11. Trade-off nima degani?

↳ Bitta qobiliyat ikkingchi qobiliyatni pasaytirvorishi. Misol model aqilli ishlasa, usha model sekin ishlaydi.

12. Frontier model nima?

↳ hozrgi eng kuchli modellar. Juda katta companylar ularni uqitisholadi.

13. Emergent ability (pando bo'luvchi qobiliyat) nima?

↳ Model ning parameterlari oshgan sari, oldin qilolmagan yangi qobiliyatlar ning paydo bulishi. Bunda model ning natijasi birdaniga yaxshilanadi. LLM da buladi.

14. Scaling Law nima?

↳ Model hajmi oshishi bilan samaradorlikning oshish qonuniyati

15. Chinchilla qoidasi nimani anglatadi?

↳ Modelni optimal train qilish uchun tokenlar soni parameterlar sonidan taxminan x20 kup bulishi kerak

16. Alignment nima?

↳ language modelni inson niyatlariga, maqsadlariga zararsiz bulishiga yunaltirish jarayoni

17. SFT (Supervised Fine-Tuning) nima?

↳ Model insonga qanday tugri javob berishni urgatish usuli.

18. RLHF nima?

↳ Inson tomonidan feedback olish.

19. Transformer arxitekturasini nima uchun muhim hisoblanadi?

↳ Kuchli boshli self-attention va MLP qatlamlari. Barcha tokenlar parallel ishlaydi va kuchli LLM yasashda asosiy arxitektura hisoblanadi

20. FLOP nima?

↳ NN ni hisoblash narhini ulchashning standard birligi

21. MFU (Model FLOPs Utilization) nima?

↳ Model GPU dan umumiy necha foiz ishlatishi. Tahminan ~50% bulsa yaxshi degani.

22. BF16, FP16 va FP32 formatlari o'rtasidagi asosiy farq nimada?

↳ FP32: eng aniq format, standard hisoblanadi

FP16: memory ni kam ishlatadi, lekin dynamic range kichikroq

BF16: FP32 bilan birhil dynamic range'ga ega va LLM training uchun qulayroq

23. AdamW optimizer nima uchun LLM trainingda standart hisoblanadi?

↳ LLM training uchun eng mos optimizernlardan biri hisoblanadi

24. Xavier initialization nima uchun kerak?

↳ Xavier initialization – Neural Network dagi boshlang'ich weightlarni tanlash uchun kerak.

25. Activation checkpointing nima?

↳ GPU ni tejash usuli. hamma activationlarni save qilmasdan. Faqat keraklarini save qiladi. va natijada memory kamayadi. Lekin training o'zgina sekinlashadi.

[Follow-Up Questions 25]:

1. Nega hozir ko'p odamlar yangi model qurish o'rniga eski (tayyor) modellardan foydalanishyapti?

↳ Chunki modelni 0 dan train qilish qimmat va kup GPU talab qiladi. Hozir kupchilik tayyor modellar dan API yoki prompt engineering orqali foydalanadi

2. Scaling Laws va Chinchilla qoidasi bir-biridan qanday farq qiladi?

↳ Scaling Law: Model hajmi oshishi bilan samaradorlikning oshish qonuniyati
Chinchilla: tokenlar soni va parameter ning optimal nisbatini x20 kursatadi

3. Nega data sifati va miqdori LLM larda boshqa AI modellariga qaraganda muhimroq hisoblanadi?

↳ Chunki LLM juda katta hajmdagi matn bilan train qilinadi. Agar data sifatsiz bulsa, model ham yomon natija beradi

4. Token va so'zlar doimo bir xilmi? Barcha holatlarni (character, word BPE) misollar bilan tushuntiring.

↳ Yuq, hardoin birxil emas

Byte Tokenization: umumiy bytelar bilan token buladi

Word Tokenization: har bir suz bitta token buladi

Character Tokenization: har bir harf alohida token buladi

BPE Tokenization: suz manoli bularlarga bulinadi

5. Parametrlar sonini bilganimizdan keyin qolgan to'rtta hisob-kitob — compute, vaqt, narx, samaradorlik — bir-biriga qanday bog'lanadi?

↳ Parameterlar soni qancha kup bulgan sari qolgan featurelar ham mashtablashadi.

6. Kichik va katta modellar xatti-harakati nima uchun farq qiladi?

Attention va MLP FLOPs taqsimoti misolida tushuntiring.

↳ Kichik modellarda Attention FLOPs va MLP FLOPs deyarli teng buladi, katta modellarda esa MLP FLOPs kuqroq buladi

7. "Har bir FLOP uchun maksimal intellekt" mantig'i nima uchun CS336 mindsetining markazida turadi?

↳ Maqsad katta model qurish emas, balki har bir FLOP dan maximal foydalanishdir.

8. OpenAI 'ning haqiqiy innovatsiyasi nima edi — yangi texnik yechimmi yoki falsafiy/strategik qarormi? Dalillar bilantushuntiring.

↳ Tayyor katta modellarni yasash va ularni kup odamlar foydalanodigon qilib API orqali taqdim qilish

9. Nega GPT-3 Chinchilla nuqtai nazaridan "under-trained" (yetarlicha o'qitilmagan) hisoblanadi?

↳ Chinchilla qoidasiga kura tokenlar soni parameterlardan taxminan 20 baravar kup bulishi kerak. GPT-3 da esa bunga tuliq mol kelmagani uchun under-trained deb hisoblanadi

10. BPE nima uchun character-level yoki word-level tokenizationdan afzalroq?

↳ Kam uchraydigon suzlarniham qayta ishlaydi va lugat hajmini samarali saqlaydi.

11. Nega FP16 xavfli, lekin BF16 xavfsiz hisoblanadi? Kichik gradient qiymati (masalan $1e-8$) misolida tushuntiring.

↳ FP16 kichik qiymatlarni yomon ifodalaydi. Shunga $1e-8$ kabi gradient 0 ga aylanishi mumkin.

12. 6ND (yoki 6NT) formulasi qayerdan kelib chiqadi? Forward va backward pass FLOPlarini alohida ko'rsatib izohlang.

↳ Forward pass tahminan 2ND FLOPs, backward pass esa 4ND FLOPs. Jami 6ND FLOPs.

13. MFU nima uchun hech qachon 100% ga yeta olmaydi?

↳ Chunki GPU ni boshqa ishlariham bor. Memory access, communication, kernel overhead. Shu sababli hisoblash resourcelarning bir qismi bekor qoladi.

14. AdamW bilan trainingda nega har bir parametrga 16 bayt xotira kerak bo'ladi? Har bir komponentni (weight, gradient, m, v) alohida tushuntiring.

↳ AdamW har bir parameter uchun 4ta qiymat saqlaydi. Har biri 4 byte, jami 16 byte memory kerak buladi

Weight (4B) - model ning asosiy parametri
Gradient (4B) - parameter qanday uzgarishini kursatadi
Adam m (4B) - gradient ning urtacha yunalishini saqlaydi
Adam v (4B) - gradient ning kattaligini saqlaydi

15. Xotira GPUga sig'masa (OOM xatosi), qanday yechimlar mavjud?

➡ Bunday holda batch sizeni kamaytirish, kichiroq model ishlatish yoki kuproq GPU dan foydalansa buladi

16. MFU ni oshirish yoki precisionni to'g'ri tanlash orqali trening narxini qanday kamaytirish mumkin? Raqamli misol bilan tushuntiring.

➡ MFU oshsa, GPU samaraliroq ishlaydi va training tezroq buladi. misol, MFU 40% dan 80% ga oshsa, training vaqti taxminan 2 baravar kamayadi. precisionni FP32 dan FP16 ga tushirish esa memory usage ni 2 baravar kamaytiradi.

17. Emergence hodisasi tufayli kichik modeldagi natijalarni katta modelga chiziqli ekstrapolyatsiya qilib bo'lmasligi amaliyotda nimani anglatadi?

➡ model mashtablashgani sari kichik model bilan solishtirganda linear kattaymaydi. a emergence holat kutilmagan tarzda paydo buladi. linear holatda emas.

18. RLHF jarayonida reward model qanday rol o'ynaydi va u qanday o'qitiladi?

➡ model javoblarini baholaydi va qaysi javob yaxshiligini aniqlaydi

19. SFT nimani o'rgatadi va nimani o'rgata olmaydi?

➡ biz tomondan berilgan instructionlarga amal qiladi. savollarga kerakli formatda javob berishni urgatadi. nimani urgata olmaydi desak - yangi bilim va havfsizlik, murakkab qarorlarni tuliq hal qila olmaydi.

20. Pretraining va foydali assistant bo'lish orasidagi "gap" (tafovut) nimada, va bu tafovut qanday yopiladi?

➡ SFT, RLHF, Alignment - shu birnechta featurelar inson bilan bulgan 'gap'ni tuldirishda yordam beradi.

21. Common Crawl'dagi xom internet ma'lumotlarining asosiy muammolari nima, va ular qanday operatsiyalar (filtering, dedup va h.k.) bilan hal qilinadi?

➡ bu internetdan yigilgan raw malumotlar hisoblanadi. uerda duplicate kup. Spam va reklamalar kup. toxic malumotham juda kup. natijada modelni alignmentigaham tasir qiladi.

22. Nega ba'zan modelni kattalashtirishdan ko'ra data sifatini 2x oshirish ko'proq foyda beradi?

➡ datani quantity sidan kura datani qualitysi ustunroq turadi. bu SML daham bor qoyda. yaxshi quality yordamida modelni aniqligi oshadi.

23. CPU va GPU o'rtasida tensor ko'chirishda nimalarga e'tibor berish kerak, va bu xato qanday oqibatlariga (masalan, crash yoki sekinlashuv) olib kelishi mumkin?

➡ agar model GPU da a tensor esa CPU da bulsa crash hatoligi chiqad

24. Checkpoint saqlashda nega faqat model emas, balki optimizer state ham saqlanishi shart?

➡ chunki optimizer - trainingning ichki holatiniham saqlaydi. yani training tuxtagan joyidan davom etadi.

25. Kichik model (masalan, 1.21B parametr) uchun hisoblangan vaqt va narxni yirik model (masalan, 70B parametr)ga qanday masshtablash mumkin — qaysi formulalar o'zgarmay qoladi?

➡ mashtablashgandaham formulalar emas faqatkina parameterlarni soni oshadi. misol 1.21B parameterdan 70B gacha kutarsak, tahminan 58 baravar FLOPs, memory, training vaqti oshadi.

