

Lesson 3 – Questions

[**Basic Questions 10**]:

1. Pre-training va post-training farqi nima? Har bir bosqichda modelda nima o'zgaradi qaysi biri ko'proq data talab qiladi?

➤ Pre-training - Next tokenni predict qiladi, va juda ko'p data kerak buladi. chunki, model basic grammary va logiclarni urganadi

Post-training - Pre-training dan keyin buladi va ko'p data kerak bulmaydi

--> Pre-training ko'proq data talab qiladi.

2. Common Crawl'ni to'g'ridan-to'g'ri training uchun ishlatib bo'lmaydi. Nega?

➤ Common Crawl ichida spam, reklama, xatto va bir hil malumotlar (duplication) ko'p. Shunga training dan oldin uni cleaning, filtering va deduplication qilish kerak

3. FineWeb nima va u Common Crawl'dan qanday olingan?

➤ Common Crawl dan olingan toza va sifatliroq data (filtered, deduplicated)

4. LLM loyihasida .gitignore ichida nima bo'lishi kerak va nega?

➤ .env, API key, Token, venv, __pycache__, modelni weightlari, datasetlar, repo ga chiqqan maydigon file, va muhim file etc. Bu projectni havfsiz saqlash uchun kerak buladi

5. API key yoki token repositoryga tushib qolsa nima qilasiz?

➤ Birinchi API key/tokenni srazi uchiramiz yoki revoke qilamiz. Keyin yangi key yasaymiz. Keyin esa, .env orqali saqlaymiz va .gitignore ga .env ni qushamiz

6. Pre-training uchun nega CPU emas, GPU ishlatiladi? Nima uchun GPU LLM da kerak? Nima uchun Vis code + Google colab

➤ LLM training da juda ko'p matrix calculation buladi. GPU bunday hisoblarni CPU ga qaraganda tezroq bajaradi.

VS Code - code yozish uchun qulay

Google Colab - GPU da training qilish uchun

7. Data mixture nima va nega bitta dataset yetarli emas?

- Data Mixture - bir nechta data sourcelardan kerakli qismlarini olib natijada yaxshi mix bulingan data orqali training qilish usul.
Bitta dataset yetarli emas, chunki model har hil malumotlarni urganishi kerak buladi. Yani, quality dimension -> diversion

8. Deduplication nima va nega training'dan oldin qilinadi?

- Deduplication - Malumotlar tuplamida ortiqcha takrorlanishlarning oldini olish uchun bir xil malumotlarni topish va uchirish. Training da oldin qilinish sababi, duplicate datalarni yuqotib, sifatli data qilish

9. Nega ko'proq data avtomatik ravishda yaxshiroq modelni anglatmaydi?

- Chunki data quality juda muhim. Masalan, 1 million yomon data dan kura, 500 mingta sifatli data yaxshiroq bulishi mumkin

10. MIT litsenziyali dataset ustida model o'rgatsangiz, sizdan nima talab qilinadi?

- Deyarli barchasiga ruhsat bor. Hatto commercialga ham. Lekin copyright va MIT license ni bildirib quyish kerak

[Intermediate Questions 10]:

1. Coding'ga yo'naltirilgan LLM uchun data mixture tuzing va har bir foizni asoslang.

- Code - 60% --> Model ni asosiy vazifasi ekani uchun
Technical text - 20% --> programming va textic tushunchalarni tushunish uchun
General text - 15% --> umumiy bilim va language ability uchun
Instruction data - 5% --> user bergan instructionni yaxshi bararishi uchun

2. Compute sarflashdan oldin korpus sifatini qanday o'lchaysiz?

- Birinchi kichik sample olib tekshiramiz:
 - duplicate, spam, bad text qancha?
 - language qanday
 - code quality qanday?

Keyin validation test qilib, data modelga foyda berib sifati yaxshi bulsa, katta compute ishlatamiz

3. Qattiq filtratsiya va data hajmini saqlash o'rtasidagi trade-off nimada?

- Qattiq filtering - data sifati oshadi, lekin kup kerakli data yuqolishi mumkin
- Yenlig filtering - kuproq data qoladi, lekin sifatsiz data ham qolib ketadi
- Shuning uchun quality va quantity orasida balance kerak buladi.

4. Web korpusda benchmark leakage (test contamination) ni qanday aniqlaysiz?

- Benchmark dagi test questions va answers ni web corpus bilan solishtiramiz.

Agar test data yoki unga juda uxshash text training datada bulsa, bu contamination hisoblanadi.

5. Exact va fuzzy (MinHash/LSH) dedup — qachon qaysi biri?

- Exact dedup - text aynan bir hil bulsa ishlatiladi, tez va oddiy
- Fuzzy dedup - text biroz uzgargan, lekin manosi yoki tarkibi uxshash

6. Datasetning 80% ingliz tilida, mahsulot esa o'zbek tilidagi foydalanuvchilar uchun. Nima qilasiz?

- Uzbek data ulushini oshiraman

Misol:

Uzbek - 50%

English - 30%

Other languages - 20%

Va bundan tashqari Uzbek language uchun alohida high-quality data yigaman

7. Qanday safety va PII filtratsiyasini qo'llaysiz va overfiltering xavfi nimada? Gitignore xavfsizlik mexanizimi? Nimaga?

- PII filtering - phone number, emas kabi shaxsiy malumotlarni olib tashlaymiz.

Safety filtering - zararli yoki havfli content ni kamaytiramiz.

Lekin juda qattiq filtering qilsa, foydali data ham yuqolishi mumkin. -> overfiltering .gitignore esa, API key, token, kabi maxfiy filelarni repository ga yubormaslik uchun

8. Pre-training data va post-training (SFT/preference) data qanday farq qiladi?

- Pre-training data - juda katta va turli hil data. Model bundan language va knowledge ni urganadi

SFT data - question + good answer kabi tayyor misollar.

Model instruction bajarishni urganadi.

Preference data - qaysi javob yaxshi, qaysinisi yomon ekanini kursatadi.
Model yaxshiroq javob tanlashni urganadi

9. Repo'da 200GB data va 40GB checkpoint bor. Buni Git'siz qanday versiyalaysiz?

↳ Object storage yoki data versioning tools ishlatamiz.

Masalan:

Data --> DVC / Object Storage

Checkpoint --> Object Storage

10. Dataset CC-BY-NC litsenziyasida. Uni commercial modelda ishlata olasizmi?

↳ Yuq, odatda ishlata olmaymiz.

CC-BY-NC dagi NC = Non-Commercial. Yani dataset commercial use uchun ruhsat bermaydi. Shuning uchun commercial model training da ishlatishdan oldin, boshqa license yoki permission kerak buladi.

[**Advanced Questions 10**]:

1. Compute budget qat'iy. Uni ko'proq data va ko'proq parametr o'rtasida qanday taqsimlaysiz?

↳ Compute budget qat'iy bulsa, parameters va training data urtasida optimal balance tanlanadi. Juda kup parameters compute costni oshiradi, juda kup data esa training costni oshiradi. Shuning uchun optimal model size va yetarli high-quality data tanlanadi.

2. Common Crawl WARC'dan training-ready shard'gacha bo'lgan pipeline'ni bosqichma-bosqich tasvirlang.

↳ Unique tokenlar tugab, datani multi-epoch qilish same data ni modelga qayta-qayta kursatishga olib keladi. Bu overfitting xavfini oshiradi va model yangi datani kamroq urganadi.

3. Mixture og'irliklarini intuitsiya emas, empirik tarzda qanday tanlaysiz?

↳ Mixture weights ni birinchi taxminan belgilab, keyin validation loss orqali tekshiramiz. Bir nechta variantni sinab kurib, qaysi weight combination eng yaxshi natija berishini tanlaymiz. Yani, intuition emas, experiment va validation results asosida belgilanadi.

4. Unique token tugasa, datani takrorlash (multi-epoch) nimaga olib keladi?

- Unique token tugasa va data takrorlansa, model bir xil malumotni qayta qayta kruadi. Bu overfitting xavfini oshiradi va yangi patternlarni urganishni kamaytirishi mumkin.

5. Quality classifier 'Wikipedia-ga o'xshash' matnni afzal ko'rsa, korpusda nima yo'qoladi?

- Wikipedia ga uxshash textlarni kuproq tanlasa, corpus ta informal, conversational, creative va niche content kamayib ketadi. Natijada, model real hayotdagi turli xil yozish usullarini kamroq urganadi.

6. Metrika o'sishiga aynan data o'zgarishi sabab bo'lganini qanday isbotlaysiz?

- Buni controlled experiment orqali tekshiramiz. Model architecture, hyperparameters va compute bir xil qoladi, faqat data uzgartiriladi. Keyin validation metrics ni solishtiramiz. Agar yaxshilanish aynan data uzgarganda paydo bulsa, sabab data ekanini katta confidence bilan aytish mumkin.

7. Model training matnini so'zma-so'z qaytarmoqda. Sabab, aniqlash va data darajasidagi yechim?

- Sabab: training data ichida bir xil yoki juda kop takrorlangan text bor, model uni yodlab olgan.

Aniqlash: model chiqargan textni training data bilan solishtirib, exact match va duplicate rate ni tekshiramiz.

Data darajasidagi yechim: duplicate va near-duplicate textlarni olib tashlash, data diversity ni oshirish va training data ni yaxshiroq filter qilish.

8. Ochiq relizga tayyorlanayotgan model uchun audit qilinadigan data provenance qanday quriladi?

- Har bir data uchun source, license, collection date va preprocessing malumotlarini saqlaymiz. Shunda data qayerdan kelgani va qanday ishlatilgani tekshiriladi.

9. Training davomida data mixture'ni o'zgartirasizmi? Mexanizmi bilan asoslang.

- Ha, kerak bulsa training davomida data mixture ni uzgartirish mumkin. Masalan, boshida umumiy data kuproq, keyin esa high-quality datani oshiramiz. Buni validation loss va boshqa metrics natijalariga qarab boshqaramiz.

10. Data tozalashni to'xtatib, training'ni boshlash vaqtini qanday belgilaysiz?

↳ Data cleaningni quality metrics stabillashganda toxtatamiz. Agar duplicate rate, filtering errors va data quality yaxshi darajaga yetgan bolsa, trainingni boshlaymiz.

[Extra Questions 10]:

1. Nima uchun biz shunchaki katta hajmdagi datasetni yuklab olib, darhol

LLM modelini train qila olmaymiz?

↳ Chunki katta dataset ichida duplicate, low-quality, noisy va casino, spam reklamalar kabi, keraksiz data bulishi mumkin. Agar uni filterlamasdan train qilsak, model notugri yoki takroriy malumotlarni urganishi va compute resourcelarni behuda sarflashi mumkin. Shuning uchun avval cleaning, filtering va deduplication qilinadi.

2. Nima uchun 10 TB dataset har doim ham 100 GB datasetdan yaxshiroq emas?

↳ Chunki dataset hajmi emas, data quality va diversity muhim. 10 TB datasetda noisy va duplicate data kop bolsa, 100 GB high-quality data undan foydaliroq bulishi mumkin.

3. Agar datasetimizda juda ko'p takroriy (duplicate) hujjatlar bo'lsa, nima bo'lishi mumkin?

↳ Agar datasetda duplicate documentlar juda kop bolsa, model bir xil malumotni qayta-qayta koradi. Bu overfittingga olib kelishi, data diversityni kamaytirishi va compute ni isrof qilishi mumkin.

4. Nima uchun coding LLM umumiy maqsaddagi LLMdan (general-purpose LLM) farqli data mixture talab qiladi?

↳ Chunki coding LLM ga code va technical data kuproq kerak buladi. General-purpose LLM esa turli xil text, conversation va knowledge bilan train qilinadi. Shuning uchun coding LLMda code data ulushi yuqoriroq buladi.

5. Nima uchun API keylarni GitHub'ga saqlamasligimiz kerak?

↳ Chunki API key GitHubga tushsa, boshqalar uni kurib, bizning API keyimizdan foydalanishi mumkin. Bu security risk va kutilmagan xarajatlarga olib kelishi mumkin. API keylarni environment variables yoki .env faylda saqlash kerak. va .gitignore ga yozib quyish

kerak

6. Agar model.pt faylini .gitignore ichiga qo'shsak, nima sodir bo'ladi?

➡ Agar model.pt ni .gitignore ga qushsak, Git bu fileni track qilmaydi va GitHubga yubormaydi. Bu katta model filellari uchun foydali, chunki repository hajmini oshirmaydi

7. Agar password.txt avval GitHub'ga commit qilingan bo'lsa va keyin

.gitignore ga qo'shilsa, secret avtomatik ravishda xavfsiz bo'lib qoladimi?

➡ Yuq! .gitignore ga keyin qushish oldingi commitdagi secretni ochirmaydi. Secret Git historyda qoladi.

Shuning uchun:

API key yoki passwordni darhol revoke/change qilish kerak.

Keyin password.txt ni .gitignore ga qushish kerak.

Kerak bulsa, Git historydan ham tozalash kerak.

8. LLM yaratishda dataset license nima uchun muhim?

➡ Dataset license muhim, chunki u datani LLM trainingda ishlatishga ruxsat bor yoki yuqligini belgilaydi. Notugri license bilan data ishlatilsa, keyinchalik legal muammo chiqishi mumkin.

9. Data quality va model quality o'rtasida qanday bog'liqlik bor?

➡ Data quality va model quality bevosita bogliq. High-quality data modelga togri va foydali patternlarni orgatadi, natijada model sifati yuqori boladi. Low-quality data esa noise va xatolarni orgatib, model natijasini yomonlashtiradi.

10. Agar sizda GPU va training data cheklangan bo'lsa, ko'proq past

sifatli datani tanlaysizmi yoki kamroq yuqori sifatli datani?

Qaroringizni tushuntiring.

➡ Men kamroq, lekin high-quality data ni tanlayman. Chunki GPU va training time cheklanganida, sifatli data modelga foydaliroq patternlarni urgatadi va compute samaraliroq ishlatiladi. va bu law supervised-machine learning dan beri keladi. yani, datani quality si > datani quantaty sidan

