


LLM: Data Engineering Pipeline

Loyihani structure i tahminan quyidagi kurinishda buladi:



✗ data & checkpoints hechqachon GitHub ga chiqmaydi.

Har bir run uchun config file buladi.

1. Datasetni load qivolamiz. Undan keyin, data/raw ga jsonl formatda save qilamiz.

Raw data – HTML formatda buladi. ushanga, turli HTML taglarni olib tashlaymiz va whitespace etc. kabi narsalardan tozalavolamiz.

2. Filtering bosqichida – language id ga threshold beramiz va juda qisqa yokida uzun matn/hujjatlarni filterlaymiz. Blacklist buyicha ham filterlaymiz. Yani, malum bir suzlarni (spam etc.) filterlaydi

Lekin yuqori threshold bersak, kerakli malumotlar tushib qoladi. Chunki misol ular qisqa bulishi mumkin. aksincha, pastroq threshold bersak noisy va toxic malumotlarniham ovoradi. Shuning uchun measured threshold kerak. U esa, sonlarni shunchaki random bermasdan bizning datasetimiz uchun test set asosida ideal balance topish

3. Deduplication stage – datada (hujjatda) qaytaraladigon malumot bulsa ularni olib tashlash. Yani duplicate datalarni drop qilish usul

4. PII Scrubbing – emails, phone-numbers, any kind of private information larni urnini boshqa raqamlar bilan almashtirish (masking). 3 hil usullari bor:

1. Redaction: Bu malumotlar shaxsiy ligi uchun olinmaydi
2. Anonymization: phone-number, location etc. larni urniga 'naming' qilib ketadi.

3. **Pseudonymization**: shaxsiy malumotlarni urniga fake data bilan almashtiradi.

✂ PII Scrabbing malumotlarni kesayotkanda private va yuqorida utilgan malumotlarni kesadi. Lekin, ular bilan birga kerakli malumotlarni ham kesvorish mumkin. U holat **over-scrabbing** deyiladi. Yani, model va umumiy context uchun kerakli malumotlarni ham kesib tashlaydi (private deb uylab). Misol, **nyuton** va shunga uxshagan **terminlari**, **brandlarni** yoki **pullarni**.

Data prepare ni asosiy qismi shu bilan tugaydi. Keyingi stage **data mixture** va **tokenization** buladi. **data** keyingi bosqich uchun **tayyor** holda yani, **toza va alo quality** ga ega bulishi kerak.

=====

10 REJECTED DOCUMENTS

=====

--- REJECTED 1 ---

Instruction: instruction

Output: output

Characters: 39

--- REJECTED 2 ---

Instruction: instruction

Output: output

Characters: 39

--- REJECTED 3 ---

Instruction: instruction

Output: output

Characters: 39

--- REJECTED 4 ---

Instruction: instruction

Output: output

Characters: 39

Filtering (200 ta dan kamlarni drop) dan keyin, **75 document** uchib ketgan. Ularni **inspect_removed.ipynb** file orqali tekshirib kursak yuqoridagi natijani kurishimiz mumkin. **dataset** **ozgina hato** yasalgan. Key va value larni ham raw data qatorida joylashgan.