

LLM: Model Building

Attention: Ilm model architecture da embedding dan keyingi bosqich. Bu FFN bilan parallel ishlaydi.

Attention qanday ishlaydi: oldingi eski modellar matnni uqigandan keyin boshidagi suzlarni esidab chiqarib quyasidi. Shuning uchun, modelga bitta kuzda hamma matnni kurishni urgatish kerak bulgan. Natijada, suzlarni bir-biri bilan boglaydigon attention yasalgan.

Ex) Men hali bank ga borib pul chiqarvoldim -> attention bu matn da 'bank' bilan 'pul' ni bir-biri bilan ulaydi va model umumiy context ni tushunadi.

Attention (Simple): hamma suzni birdaniga kuradi u matndagi oldingi va keyingi suzlarni bir-biriga boglab umumiy manoni tushunish uchun ishlatiladi. Input encoderda

Causal Attention: kelajakni kura olmaydi unda har bir suz faqat uzidan oldingi suzlarni kuradi xolos. bu narsa modelni matn yozayotganda keyingi suzni kurib qolib javobni kuchirvolmasligi va uzi mustaqil uylab yangi gap tuzishi uchun kerak buladi. Text decoder

FFN: modelning miyyasi bulib urgangan concept/bilim larni saqlab qoladi.

`ffn_mult: 4` bulsa model dimension – 4x baravar kengayadi. Natijada, kuproq malumot qabul qiladi.

Transformer: modelning asosiy fundament. shu jarayonda hidden layerlar va attention, FFN, Activation function buladi. transformer block bitta bulmaydi, bir nechta layerdan tashkil etkan buladi.

Residual Connection: layerdan layerga utyotkanda malumotlar yuqolib qolishi mumkin. ushanga, Residual connection yasalgan. Yani, layerlar sequence ketyotkanda yana bir parallel sequence yasaladi. Weightlar va parameterlar main sequence da uzgarib boruradi, a parallel sequence da uzgarmasdan ketadi. ohirida (output) da main sequence + parallel sequence buladi. natijada, malumotlar (weight, parameters) yaxshi holda saqlanib qoladi.

