LLM: Chat Template & LORA & Data Engineering

Chat Template: modelga yuboriladigon messagelarni maxsus formatga keltirish usuli. U message kim tomonidan yuborilganini va message qayerda boshlanib, qayerda tugashini belgilaydi

System: modelning uzini tutishi va javob berish qoidalarini belgilaydi
User: foydalanuvchining savoli yoki buyruqini bildiradi.
Assistant: model tomonidan berilgan javobni bildiradi.

Template bermasak: model savollarga tugri javob berishda qiynalishi mumkin. Chunki Chat Template messagelarning role ini va tuzilishini belgilaydi. U bulmasa, model foydalanuvchi savoli va assistant javobini tugri ajratolmasligi mumkin. Natijada model savolga mos kelmaydigan javoblar berishi yoki mavjud bulmagan malumotlarni uylab topishi mumkin.

<eot_id|> (end of turn): suhbatdagi malum bir qism tugaganini bildiruvchi unique token. Uning aniq vazifasi model uqitilyotkan formatga bogliq.

System rolidan keyin: system kursatmasi tugaganini bildiradi. Model keyingi xabarga utadi.
User rolidan keyin: foydalanuvchining savoli tugaganini bildiradi. Endi model javob berishi mumkin.
Assistant rolidan keyin: model javobi tugaganini bildiradi. Agar bu token formatda javobning yakunini anglatsa, model shu yerda javobni tuxshatishni urganadi.

<EOS> tokenni asosiy 2 ta vazifasi bor:
1. Turn separation: navbat uzgaradi user → assistant
2. Global <eos> (stop): generation butunlay tuhtaydi

<|im_start|> (Message Start): suhbatdagi yangi xabar boshlanishini bildiruvchi maxsus token. U modelga xabar qayerdan boshlanishini va undan keyin qaysi role gapirayotganini kursatadi. Ushbu token xabarlarni bir-biridan ajratish va suhbat tuzilishini tugri tushunishga yordam beradi.

Parametrlarni yangilashning 2 ta asosiy usuli bor:
1. Full Fine-Tuning: Modelning barcha (100%) parameterlarini yangilaydi. Kuproq xotira va hisoblash resourcelarni talab qiladi.
2. PEFT: Model parametrlarining faqat kichik bir qismini yangilaydi. Xotira va hisoblash resurslarini tejaydi.

PEFT ning asosiy usullari:

- LoRA: Modelning barcha parametrlarini uzgartirmasdan, kichik qushimcha parameterlarni urgatadi.
- QLoRA: Model weightlarni 4-bit formatda saqlab, LoRA orqali uqitadi. Bu memory ni yanada kuproq tejaydi.