LLM: DPO

DPO (Direct Preference Optimization): modelning ikkita javobi solishtiriladi va yaxshiroq javob tanlanadi. Model shu tanlovlar asosida javobni sifatliroq va foydaliroq berishni urganadi.

Nima uchun kerak: DPO modelning javoblari sifatini oshirish, notogri yoki foydasiz javoblarni kamaytirish va foydalanuvchi talablariga yaxshiroq moslashish uchun ishlatiladi. U modelga qaysi javob yaxshiroq ekanini urgatadi.
DPO samarali ishlashi uchun tanlanadigan javoblar orasida kamida bitta yaxshi javob bulishi kerak. Agar ikkala javob ham notogri bulsa, ulardan yaxshisini tanlash qiyin va bu modelni tugri yunaltirishga yordam bermasligi mumkin.

Summary: avval modelni sifatli malumotlar bilan SFT orqali urgatish, keyin esa uning javoblarini yaxshilash uchun DPO bajariladi

---

Preference data: bu modelning ikkita yoki undan kuproq javoblari orasidan qaysi biri yaxshiroq ekanini kursatadigon malumotlar tuplami.

DPO uchun preference data odatda uchta asosiy qismdan iborat:
- Prompt: userning savoli yoki topshirigi
- Chosen response: tugri deb kurilgan, yani yaxshiroq javob.
- Rejected response: notogri deb kurilgan, yani yomonroq javob.